(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 119494085 A
(43)申请公布日 2025.02.21

(21)申请号 202510076605.7

(22)申请日 2025.01.17

(71)申请人 西安理工大学
地址 710000 陕西省西安市金花南路5号

(72)发明人 邹小彤 徐开伟 方长青 赵少华 刘轲

(74)专利代理机构 深圳科博专利代理事务所（普通合伙） 441003
专利代理师 李木燕

(51)Int.Cl.
G06F 18/27(2023.01)
G06N 20/00(2019.01)
G06F 18/15(2023.01)
G06F 18/214(2023.01)
G06F 18/243(2023.01)

权利要求书4页 说明书11页 附图3页

(54)发明名称

一种基于机器学习的微藻生长预测与优化方法及系统

(57)摘要

本发明涉及微藻生物智能控制技术领域，特别是一种基于机器学习的微藻生长预测与优化方法及系统。基于微藻生长参数的特征变量随机森林模型筛选出显著影响微藻生长的降维筛选后的特征变量数据集，通过机器学习算法的对特征变量数据集进行潜在主成分变量的回归训练，得到训练完成的微藻生长预测模型；利用训练完成的微藻生长预测模型获取培养条件动态变化下的多个实际预测结果，基于微藻生长培养的实际预测结果在遗传算法中搜索既定参数调控空间，得到最优培养条件参数集，将所述最优培养条件参数集下发至微藻生长的实际培养过程。本发明能够在多维参数空间中精确刻画微藻生长动力学，实现对微藻生长趋势与代谢产率的实时预测与调优。

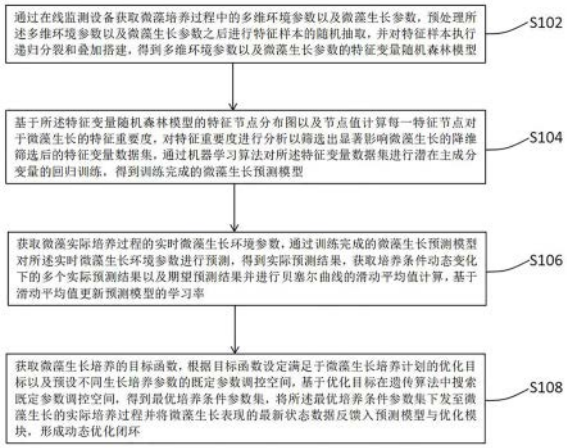

CN 119494085 A

1.一种基于机器学习的微藻生长预测与优化方法,其特征在于,包括以下步骤:

S102:通过在线监测设备获取微藻培养过程中的多维环境参数以及微藻生长参数,预处理所述多维环境参数以及微藻生长参数之后进行特征样本的随机抽取,并对特征样本执行递归分裂和叠加搭建,得到多维环境参数以及微藻生长参数的特征变量随机森林模型;

S104:基于所述特征变量随机森林模型的特征节点分布图以及节点值计算每一特征节点对于微藻生长的特征重要度,对特征重要度进行分析以筛选出显著影响微藻生长的降维筛选后的特征变量数据集,通过机器学习算法对所述特征变量数据集进行潜在主成分变量的回归训练,得到训练完成的微藻生长预测模型;

S106:获取微藻实际培养过程的实时微藻生长环境参数,通过训练完成的微藻生长预测模型对所述实时微藻生长环境参数进行预测,得到实际预测结果,获取培养条件动态变化下的多个实际预测结果以及期望预测结果并进行贝塞尔曲线的滑动平均值计算,基于滑动平均值更新预测模型的学习率;

S108:获取微藻生长培养的目标函数,根据目标函数设定满足于微藻生长培养计划的优化目标以及预设不同生长培养参数的既定参数调控空间,基于优化目标在遗传算法中搜索既定参数调控空间,得到最优培养条件参数集,将所述最优培养条件参数集下发至微藻生长的实际培养过程并将微藻生长表现的最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。

2.根据权利要求1所述的一种基于机器学习的微藻生长预测与优化方法,其特征在于,所述S102步骤,具体包括以下步骤:

通过在线监测设备上搭载的在线以及离线传感器对微藻培养环境进行实时监测,以获取微藻培养过程中的多维环境参数以及微藻生长参数;

导入数据预处理流程,通过数据预处理流程对所述微藻培养过程中的多维环境参数以及微藻生长参数进行异常值检测、缺失值插补并执行归一化处理,得到预处理后的多维环境参数以及微藻生长参数;

随机抽取所述预处理后的多维环境参数以及微藻生长参数的特征样本,以构建M个Bootstrap特征变量样本集;对于每个Bootstrap特征变量样本集建立对应的一个树根节点,同时预设最佳分裂特征以及最大分裂深度;

基于最佳分裂特征从树根节点开始对Bootstrap特征变量样本集执行特征节点的递归分裂操作,判断当前分裂深度是否达到最大分裂深度;

若未达到,则继续递归分裂Bootstrap特征变量样本集的特征节点;若已达到,停止递归分裂操作,生成每个Bootstrap特征变量样本集的子决策树;最终对全部Bootstrap特征变量样本集的子决策树进行叠加搭建,得到多维环境参数以及微藻生长参数的特征变量随机森林模型。

3.根据权利要求1所述的一种基于机器学习的微藻生长预测与优化方法,其特征在于,所述S104步骤,具体包括以下步骤:

提取所述特征变量随机森林模型的特征节点分布图以及每一特征节点的节点值,基于每一特征节点的节点值对特征变量随机森林模型处于特征节点分布图条件下的初始误差进行计算,得到每一特征节点对于特征变量随机森林模型的初始均方误差;

获取微藻生长预测需求,根据微藻生长预测需求预设每一特征节点的扰动阈值,通过

扰动阈值对特征变量随机森林模型中的每个特征节点进行扰动并重新计算误差,得到扰动每一特征节点后对于特征变量随机森林模型的扰动均方误差;

计算扰动均方误差相较于初始均方误差之间的均方误差增量,根据所述均方误差增量确定每一特征节点对于微藻生长的特征重要度;

若均方误差幅度显示为负值,说明该特征节点对特征变量随机森林模型的预测性能影响较小,即特征重要度较低,则剔除该扰动均方误差对应的特征节点;

若均方误差幅度显示为正值,说明该特征节点对特征变量随机森林模型的预测性能有较大的影响,代表特征重要度较高,则提取该扰动均方误差对应的特征节点,标记为高重要度特征节点;

整合预处理后多维环境参数以及微藻生长参数中所保留的全部高重要度特征节点对应的数据,得到降维筛选后的特征变量数据集;

引入偏最小二乘回归算法,通过偏最小二乘回归算法对所述特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练,得到训练完成的微藻生长预测模型。

4.根据权利要求3所述的一种基于机器学习的微藻生长预测与优化方法,其特征在于,所述引入偏最小二乘回归算法,通过偏最小二乘回归算法对所述特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练,得到训练完成的微藻生长预测模型,具体包括以下步骤:

以环境参数为输入特征、微藻生长趋势与代谢产量为输出特征,基于所述降维筛选后的特征变量数据集计算构建输入特征-输出特征协方差矩阵;

引入偏最小二乘回归算法,预设最大协方差距离阈值,通过偏最小二乘回归算法计算输入特征-输出特征协方差矩阵中每个输入特征与每一输出特征之间的协方差距离,得到输入特征-输出特征协方差矩阵内每一矩阵节点的协方差距离;

对于输入特征-输出特征协方差矩阵内的每一个矩阵节点,若协方差距离小于最大协方差距离阈值,则忽略该协方差距离对应的矩阵节点;若协方差距离大于最大协方差距离阈值,则标记出该协方差距离对应的矩阵节点,定义为最大相关性矩阵节点;

提取最大相关性矩阵节点上关联的输入特征以及输出特征,定义为一组潜在主成分变量,并预设潜在主成分变量的提取数量临界值;

重复上述协方差距离计算判定与输入特征-输出特征协方差矩阵中潜在主成分变量提取的步骤,每次提取一组潜在主成分变量,则更新迭代输入特征与输出特征之间的关系,得到潜在主成分变量的当前提取数量;

若当前提取数量未达到所述提取数量临界值,则继续输入特征-输出特征协方差矩阵的协方差距离计算判定与潜在主成分变量提取;若当前提取数量已达到所述提取数量临界值,则停止潜在主成分变量提取,得到提取出的潜在主成分变量集;

利用所述提取出的潜在主成分变量集在偏最小二乘回归算法中构建输入特征与输出特征之间的回归模型,通过所述回归模型对训练集进行回归训练运算,得到训练完成的微藻生长预测模型。

5.根据权利要求1所述的一种基于机器学习的微藻生长预测与优化方法,其特征在于,所述S106步骤,具体包括以下步骤:

获取微藻实际培养过程的实时微藻生长环境参数,将所述实时微藻生长环境参数导入

训练完成的微藻生长预测模型进行未来时间段的生长预测,以输出未来特定时间段内的实际微藻生长预测趋势与实际代谢预测产量;

获取微藻生长预测模型处于预设培养时序上预测培养条件动态变化时输出的实际微藻生长预测趋势与实际代谢预测产量,得到培养条件动态变化时的多个实际预测结果;

引入贝塞尔曲线法,通过贝塞尔曲线法将多个所述实际预测结果进行曲线拟合,得到实际预测结果的贝塞尔曲线,定义为第一贝塞尔曲线;同步获取培养条件动态变化下的期望预测结果,构建期望预测结果的贝塞尔曲线,定义为第二贝塞尔曲线;

若第一贝塞尔曲线的斜率与第二贝塞尔曲线的斜率之间的斜率偏差值大于预设斜率偏差值,则基于斜率偏差值跟踪训练完成的微藻生长预测模型位于培养条件动态变化过程中的历史梯度平方并进行指数加权,得到一个滑动平均值;

跟踪过程中,获取微藻生长预测模型的当前学习率,通过滑动平均值对所述当前学习率进行调整更新,以使得训练完成的微藻生长预测模型适应动态变化的培养条件。

6.根据权利要求1所述的一种基于机器学习的微藻生长预测与优化方法,其特征在于,所述S108步骤,具体包括以下步骤:

获取微藻生长培养计划,通过所述微藻生长培养计划获取微藻生长培养的目标函数;其中,所述目标函数包括最大生物量产出、最佳代谢产物合成率、最低资源消耗;

基于未来特定时间段内的微藻生长预测趋势、代谢预测产量以及所述目标函数设定满足于微藻生长培养计划的优化目标;

通过微藻生长培养计划提取不同生长培养参数的预设调控区间,根据所述不同生长培养参数的预设调控区间构建既定参数调控空间;

引入遗传算法,通过遗传算法构建既定参数调控空间的多个初始遗传种群,基于优化目标对各个初始遗传种群中的每一生长培养参数个体进行适应度评估,得到若干个适应度值;

只提取最大适应度值的生长培养参数个体,标记为父代个体,并对所述父代个体进行遗传交叉以及变异操作,生成新生子代个体,将每个初始遗传种群的新生子代个体搜索替代对应的父代个体,直至种群适应度达到预设适应度阈值为止,最终输出微藻生长的最优培养条件参数集;

通过闭环控制策略,将所述最优培养条件参数集下发至微藻生长的实际培养过程,以实时调节微藻生长的环境条件,并实时监控微藻生长表现将最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。

7.根据权利要求6所述的一种基于机器学习的微藻生长预测与优化方法,其特征在于,所述并实时监控微藻生长表现将最新状态数据反馈入预测模型与优化模块,形成动态优化闭环,具体包括以下步骤:

通过在线监测设备实施连续监控微藻生长状态表现,得到当前生长状态变量,并建立微藻生长培养-预测-优化的闭环状态控制模型;

引入极点配置法,通过极点配置法对所述当前生长状态变量进行闭环状态控制模型的闭环反馈计算,得到当前微藻生长状态的闭环反馈增益矩阵,将所述闭环反馈增益矩阵导入闭环状态控制模型中补偿控制,生成当前微藻生长状态的闭环反馈控制器;

将所述当前微藻生长状态的闭环反馈控制器部署于实际微藻生长培养-预测-优化流

程中,得到当前微藻生长的最新相关状态数据,并最终将最新相关状态数据反馈到微藻生长预测模型的预测模型与优化模块,以形成动态优化闭环。

8.一种基于机器学习的微藻生长预测与优化系统,其特征在于,所述微藻生长预测与优化系统包括存储器与处理器,所述存储器中储存一种基于机器学习的微藻生长预测与优化方法程序,所述微藻生长预测与优化方法程序被所述处理器执行时,实现如权利要求1-7任一项所述的微藻生长预测与优化方法步骤。

一种基于机器学习的微藻生长预测与优化方法及系统

技术领域

[0001] 本发明涉及微藻生物智能控制技术领域,尤其涉及一种基于机器学习的微藻生长预测与优化方法及系统。

背景技术

[0002] 微藻是光合自养微生物,它们可将CO_2、光能及营养元素转化为生物质和多种代谢产物。微藻生长过程和代谢特征受环境因素(例如光照强度、光照周期、温度、pH值、营养物浓度、CO_2浓度及搅拌速度等)显著影响。传统对微藻生长进行预测的方法多依赖经验模型或简单线性模型,难以精准表征多因素交互对微藻生长速率与代谢产物产量的影响。

[0003] 随着数据获取手段(传感器、在线监测设备)和储存技术的发展,人们能获得大量微藻培养过程数据。然而,如何有效挖掘这些数据中隐含的复杂非线性关系并实时预测微藻生长趋势,继而优化培养策略,是目前研究的难点和重点。

发明内容

[0004] 本发明克服了现有技术的不足,提供了一种基于机器学习的微藻生长预测与优化方法及系统。

[0005] 为达上述目的,本发明采用的技术方案为:

本发明第一方面提供了一种基于机器学习的微藻生长预测与优化方法,包括以下步骤:

S102:通过在线监测设备获取微藻培养过程中的多维环境参数以及微藻生长参数,预处理所述多维环境参数以及微藻生长参数之后进行特征样本的随机抽取,并对特征样本执行递归分裂和叠加搭建,得到多维环境参数以及微藻生长参数的特征变量随机森林模型;

S104:基于所述特征变量随机森林模型的特征节点分布图以及节点值计算每一特征节点对于微藻生长的特征重要度,对特征重要度进行分析以筛选出显著影响微藻生长的降维筛选后的特征变量数据集,通过机器学习算法对所述特征变量数据集进行潜在主成分变量的回归训练,得到训练完成的微藻生长预测模型;

S106:获取微藻实际培养过程的实时微藻生长环境参数,通过训练完成的微藻生长预测模型对所述实时微藻生长环境参数进行预测,得到实际预测结果,获取培养条件动态变化下的多个实际预测结果以及期望预测结果并进行贝塞尔曲线的滑动平均值计算,基于滑动平均值更新预测模型的学习率;

S108:获取微藻生长培养的目标函数,根据目标函数设定满足于微藻生长培养计划的优化目标以及预设不同生长培养参数的既定参数调控空间,基于优化目标在遗传算法中搜索既定参数调控空间,得到最优培养条件参数集,将所述最优培养条件参数集下发至微藻生长的实际培养过程并将微藻生长表现的最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。

[0006] 更具体地,所述S102步骤,具体包括以下步骤:

通过在线监测设备上搭载的在线以及离线传感器对微藻培养环境进行实时监测,以获取微藻培养过程中的多维环境参数以及微藻生长参数;

导入数据预处理流程,通过数据预处理流程对所述微藻培养过程中的多维环境参数以及微藻生长参数进行异常值检测、缺失值插补并执行归一化处理,得到预处理后的多维环境参数以及微藻生长参数;

随机抽取所述预处理后的多维环境参数以及微藻生长参数的特征样本,以构建M个Bootstrap特征变量样本集;对于每个Bootstrap特征变量样本集建立对应的一个树根节点,同时预设最佳分裂特征以及最大分裂深度;

基于最佳分裂特征从树根节点开始对Bootstrap特征变量样本集执行特征节点的递归分裂操作,判断当前分裂深度是否达到最大分裂深度;

若未达到,则继续递归分裂Bootstrap特征变量样本集的特征节点;若已达到,停止递归分裂操作,生成每个Bootstrap特征变量样本集的子决策树;最终对全部Bootstrap特征变量样本集的子决策树进行叠加搭建,得到多维环境参数以及微藻生长参数的特征变量随机森林模型。

[0007] 更具体地,所述S104步骤,具体包括以下步骤:

提取所述特征变量随机森林模型的特征节点分布图以及每一特征节点的节点值,基于每一特征节点的节点值对特征变量随机森林模型处于特征节点分布图条件下的初始误差进行计算,得到每一特征节点对于特征变量随机森林模型的初始均方误差;

获取微藻生长预测需求,根据微藻生长预测需求预设每一特征节点的扰动阈值,通过扰动阈值对特征变量随机森林模型中的每个特征节点进行扰动并重新计算误差,得到扰动每一特征节点后对于特征变量随机森林模型的扰动均方误差;

计算扰动均方误差相较于初始均方误差之间的均方误差增量,根据所述均方误差增量确定每一特征节点对于微藻生长的特征重要度;

若均方误差幅度显示为负值,说明该特征节点对特征变量随机森林模型的预测性能影响较小,即特征重要度较低,则剔除该扰动均方误差对应的特征节点;

若均方误差幅度显示为正值,说明该特征节点对特征变量随机森林模型的预测性能有较大的影响,代表特征重要度较高,则提取该扰动均方误差对应的特征节点,标记为高重要度特征节点;

整合预处理后多维环境参数以及微藻生长参数中所保留的全部高重要度特征节点对应的数据,得到降维筛选后的特征变量数据集;

引入偏最小二乘回归算法,通过偏最小二乘回归算法对所述特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练,得到训练完成的微藻生长预测模型。

[0008] 更具体地,所述引入偏最小二乘回归算法,通过偏最小二乘回归算法对所述特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练,得到训练完成的微藻生长预测模型,具体包括以下步骤:

以环境参数为输入特征、微藻生长趋势与代谢产量为输出特征,基于所述降维筛选后的特征变量数据集计算构建输入特征-输出特征协方差矩阵;

引入偏最小二乘回归算法,预设最大协方差距离阈值,通过偏最小二乘回归算法

计算输入特征-输出特征协方差矩阵中每个输入特征与每一输出特征之间的协方差距离，得到输入特征-输出特征协方差矩阵内每一矩阵节点的协方差距离；

对于输入特征-输出特征协方差矩阵内的每一个矩阵节点，若协方差距离小于最大协方差距离阈值，则忽略该协方差距离对应的矩阵节点；若协方差距离大于最大协方差距离阈值，则标记出该协方差距离对应的矩阵节点，定义为最大相关性矩阵节点；

提取最大相关性矩阵节点上关联的输入特征以及输出特征，定义为一组潜在主成分变量，并预设潜在主成分变量的提取数量临界值；

重复上述协方差距离计算判定与输入特征-输出特征协方差矩阵中潜在主成分变量提取的步骤，每次提取一组潜在主成分变量，则更新迭代输入特征与输出特征之间的关系，得到潜在主成分变量的当前提取数量；

若当前提取数量未达到所述提取数量临界值，则继续输入特征-输出特征协方差矩阵的协方差距离计算判定与潜在主成分变量提取；若当前提取数量已达到所述提取数量临界值，则停止潜在主成分变量提取，得到提取出的潜在主成分变量集；

利用所述提取出的潜在主成分变量集在偏最小二乘回归算法中构建输入特征与输出特征之间的回归模型，通过所述回归模型对训练集进行回归训练运算，得到训练完成的微藻生长预测模型。

[0009] 更具体地，所述S106步骤，具体包括以下步骤：

获取微藻实际培养过程的实时微藻生长环境参数，将所述实时微藻生长环境参数导入训练完成的微藻生长预测模型进行未来时间段的生长预测，以输出未来特定时间段内的实际微藻生长预测趋势与实际代谢预测产量；

获取微藻生长预测模型处于预设培养时序上预测培养条件动态变化时输出的实际微藻生长预测趋势与实际代谢预测产量，得到培养条件动态变化时的多个实际预测结果；

引入贝塞尔曲线法，通过贝塞尔曲线法将多个所述实际预测结果进行曲线拟合，得到实际预测结果的贝塞尔曲线，定义为第一贝塞尔曲线；同步获取培养条件动态变化下的期望预测结果，构建期望预测结果的贝塞尔曲线，定义为第二贝塞尔曲线；

若第一贝塞尔曲线的斜率与第二贝塞尔曲线的斜率之间的斜率偏差值大于预设斜率偏差值，则基于斜率偏差值跟踪训练完成的微藻生长预测模型位于培养条件动态变化过程中的历史梯度平方并进行指数加权，得到一个滑动平均值；

跟踪过程中，获取微藻生长预测模型的当前学习率，通过滑动平均值对所述当前学习率进行调整更新，以使得训练完成的微藻生长预测模型适应动态变化的培养条件。

[0010] 更具体地，所述S108步骤，具体包括以下步骤：

获取微藻生长培养计划，通过所述微藻生长培养计划获取微藻生长培养的目标函数；其中，所述目标函数包括最大生物量产出、最佳代谢产物合成率、最低资源消耗；

基于未来特定时间段内的微藻生长预测趋势、代谢预测产量以及所述目标函数设定满足于微藻生长培养计划的优化目标；

通过微藻生长培养计划提取不同生长培养参数的预设调控区间，根据所述不同生长培养参数的预设调控区间构建既定参数调控空间；

引入遗传算法，通过遗传算法构建既定参数调控空间的多个初始遗传种群，基于

优化目标对各个初始遗传种群中的每一生长培养参数个体进行适应度评估,得到若干个适应度值;

只提取最大适应度值的生长培养参数个体,标记为父代个体,并对所述父代个体进行遗传交叉以及变异操作,生成新生子代个体,将每个初始遗传种群的新生子代个体搜索替代对应的父代个体,直至种群适应度达到预设适应度阈值为止,最终输出微藻生长的最优培养条件参数集;

通过闭环控制策略,将所述最优培养条件参数集下发至微藻生长的实际培养过程,以实时调节微藻生长的环境条件,并实时监控微藻生长表现将最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。

[0011] 更具体地,所述并实时监控微藻生长表现将最新状态数据反馈入预测模型与优化模块,形成动态优化闭环,具体包括以下步骤:

通过在线监测设备实施连续监控微藻生长状态表现,得到当前生长状态变量,并建立微藻生长培养-预测-优化的闭环状态控制模型;

引入极点配置法,通过极点配置法对所述当前生长状态变量进行闭环状态控制模型的闭环反馈计算,得到当前微藻生长状态的闭环反馈增益矩阵,将所述闭环反馈增益矩阵导入闭环状态控制模型中补偿控制,生成当前微藻生长状态的闭环反馈控制器;

将所述当前微藻生长状态的闭环反馈控制器部署于实际微藻生长培养-预测-优化流程中,得到当前微藻生长的最新相关状态数据,并最终将最新相关状态数据反馈到微藻生长预测模型的预测模型与优化模块,以形成动态优化闭环。

[0012] 本发明第二方面提供了一种基于机器学习的微藻生长预测与优化系统,所述微藻生长预测与优化系统包括存储器与处理器,所述存储器中储存一种基于机器学习的微藻生长预测与优化方法程序,所述微藻生长预测与优化方法程序被所述处理器执行时,实现任一项所述的微藻生长预测与优化方法步骤。

[0013] 本发明解决了背景技术中存在的技术缺陷,本发明的有益技术效果在于:

预处理微藻培养过程中的多维环境参数以及微藻生长参数,并进行特征样本的随机抽取以及递归分裂,得到多维环境参数以及微藻生长参数的特征变量随机森林模型;基于特征变量随机森林模型计算每一特征节点对于微藻生长的特征重要度,根据特征重要度筛选出显著影响微藻生长的降维筛选后的特征变量数据集,通过机器学习算法对特征变量数据集进行潜在主成分变量的回归训练,得到训练完成的微藻生长预测模型;利用训练完成的微藻生长预测模型预测实时微藻生长环境参数得到实际预测结果,获取培养条件动态变化下的多个实际预测结果以及期望预测结果并进行贝塞尔曲线的滑动平均值计算,基于滑动平均值更新预测模型的学习率;根据微藻生长培养的目标函数设定满足于微藻生长培养计划的优化目标,基于优化目标在遗传算法中搜索既定参数调控空间,得到最优培养条件参数集,将所述最优培养条件参数集下发至微藻生长的实际培养过程并将微藻生长表现的最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。本发明通过融合多源数据与先进的机器学习算法,本发明能够在多维参数空间中精确刻画微藻生长动力学,实现对生长趋势与代谢产率的实时预测与调优。可有效提升微藻培养效率,降低运营成本,实现培养条件的自动或半自动优化,提高微藻产量与目标代谢产物的合成效率。

附图说明

[0014] 为了更清楚地说明本发明实施例或现有技术中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是本发明的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他实施例的附图。

[0015] 图1示出了一种基于机器学习的微藻生长预测与优化方法的第一方法流程图;

图2示出了一种基于机器学习的微藻生长预测与优化方法的第二方法流程图;

图3示出了一种基于机器学习的微藻生长预测与优化系统的系统框架图。

具体实施方式

[0016] 为了能够更清楚地理解本发明的上述目的、特征和优点,下面结合附图和具体实施方式对本发明进行进一步的详细描述。需要说明的是,在不冲突的情况下,本申请的实施例及实施例中的特征可以相互组合。

[0017] 在下面的描述中阐述了很多具体细节以便于充分理解本发明,但是,本发明还可以采用其他不同于在此描述的其他方式来实施,因此,本发明的保护范围并不受下面公开的具体实施例的限制。

[0018] 本发明第一方面提供了一种基于机器学习的微藻生长预测与优化方法,如图1所示,包括以下步骤:

S102:通过在线监测设备获取微藻培养过程中的多维环境参数以及微藻生长参数,预处理所述多维环境参数以及微藻生长参数之后进行特征样本的随机抽取,并对特征样本执行递归分裂和叠加搭建,得到多维环境参数以及微藻生长参数的特征变量随机森林模型;

S104:基于所述特征变量随机森林模型的特征节点分布图以及节点值计算每一特征节点对于微藻生长的特征重要度,对特征重要度进行分析以筛选出显著影响微藻生长的降维筛选后的特征变量数据集,通过机器学习算法对所述特征变量数据集进行潜在主成分变量的回归训练,得到训练完成的微藻生长预测模型;

S106:获取微藻实际培养过程的实时微藻生长环境参数,通过训练完成的微藻生长预测模型对所述实时微藻生长环境参数进行预测,得到实际预测结果,获取培养条件动态变化下的多个实际预测结果以及期望预测结果并进行贝塞尔曲线的滑动平均值计算,基于滑动平均值更新预测模型的学习率;

S108:获取微藻生长培养的目标函数,根据目标函数设定满足于微藻生长培养计划的优化目标以及预设不同生长培养参数的既定参数调控空间,基于优化目标在遗传算法中搜索既定参数调控空间,得到最优培养条件参数集,将所述最优培养条件参数集下发至微藻生长的实际培养过程并将微藻生长表现的最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。

[0019] 更具体地,所述S102步骤,具体包括以下步骤:

通过在线监测设备上搭载的在线以及离线传感器对微藻培养环境进行实时监测,以获取微藻培养过程中的多维环境参数以及微藻生长参数;

导入数据预处理流程,通过数据预处理流程对所述微藻培养过程中的多维环境参

数以及微藻生长参数进行异常值检测、缺失值插补并执行归一化处理,得到预处理后的多维环境参数以及微藻生长参数;

随机抽取所述预处理后的多维环境参数以及微藻生长参数的特征样本,以构建M个Bootstrap特征变量样本集;对于每个Bootstrap特征变量样本集建立对应的一个树根节点,同时预设最佳分裂特征以及最大分裂深度;

基于最佳分裂特征从树根节点开始对Bootstrap特征变量样本集执行特征节点的递归分裂操作,判断当前分裂深度是否达到最大分裂深度;

若未达到,则继续递归分裂Bootstrap特征变量样本集的特征节点;若已达到,停止递归分裂操作,生成每个Bootstrap特征变量样本集的子决策树;最终对全部Bootstrap特征变量样本集的子决策树进行叠加搭建,得到多维环境参数以及微藻生长参数的特征变量随机森林模型。

[0020] 需要说明的是,由于微藻培养过程中的多维环境参数以及微藻生长参数包含有不同关于微藻生长影响的特征,如若直接将预处理所得到的多维环境参数以及微藻生长参数导入机器学习算法中进行训练,则可能导致机器学习算法训练数据时对一些影响微藻生长较低的特征变量进行过多的权重计算,从而便可能出现数据冗余现象以及过拟合的风险,这使得训练获得的微藻生长预测模型对于实际环境参数存在较大的预测误差,造成预测模型的微藻生长预测精准度与性能急剧下降,不利于实际微藻生长培养的优化。对此,本方法通过随机抽取预处理后的多维环境参数以及微藻生长参数的特征样本来构建不同微藻生长影响随机性的特征变量样本集,增加预测模型样本训练的多样性,降低不同特征变量的相关性,从而提高后续特征重要度筛选的集成效果。接着基于每个Bootstrap特征变量样本集预设的最佳分裂特征从树根节点开始对其执行特征节点的递归分裂操作,以此构建每个Bootstrap特征变量样本集的子决策树,通过构建代表不同微藻生长特征重要度随机性的子决策树的方式能够增强训练数据的拟合能力,从而使得随机森林模型的特征重要性筛选具备较高的泛化能力,能够使后续基于特征重要性筛选的微藻生长影响显著特征不存在数据训练过拟合的情况,提高微藻生长预测模型的整体性能。最终将全部子决策树叠加构建形成一个表达多维环境参数以及微藻生长参数的特征变量随机性的随机森林模型,随机森林模型能够使基于特征重要性的微藻生长影响显著特征筛选具备更好的集成效果,提高机器学习算法对于微藻生长影响显著的特征变量的训练精准度,减少预测模型的预测误差。

[0021] 需要说明的是,多维环境参数包括光照强度、温度、pH值、CO_2浓度、营养盐浓度以及搅拌速率。微藻生长参数包括细胞密度、叶绿素含量、生物量浓度及特定代谢产物浓度。通过本方法能够为后续机器学习基于特征重要性的微藻生长影响显著特征筛选提供一个数据特征集成化平台,降低传统机器学习算法对于单棵决策树可能过拟合的特征筛选现象,大幅提高影响微藻生长数据特征的训练敏感度,以减少数据冗余与过拟合风险,进一步提高预测模型性能,其中,Bootstrap 是一个常用的前端框架,包含许多类名(即特征变量)用于快速构建和设计响应式网页。

[0022] 更具体地,所述S104步骤,具体包括以下步骤:

提取所述特征变量随机森林模型的特征节点分布图以及每一特征节点的节点值,基于每一特征节点的节点值对特征变量随机森林模型处于特征节点分布图条件下的初始误差进行计算,得到每一特征节点对于特征变量随机森林模型的初始均方误差;

获取微藻生长预测需求,根据微藻生长预测需求预设每一特征节点的扰动阈值,通过扰动阈值对特征变量随机森林模型中的每个特征节点进行扰动并重新计算误差,得到扰动每一特征节点后对于特征变量随机森林模型的扰动均方误差;

计算扰动均方误差相较于初始均方误差之间的均方误差增量,根据所述均方误差增量确定每一特征节点对于微藻生长的特征重要度;

若均方误差幅度显示为负值,说明该特征节点对特征变量随机森林模型的预测性能影响较小,即特征重要度较低,则剔除该扰动均方误差对应的特征节点;

若均方误差幅度显示为正值,说明该特征节点对特征变量随机森林模型的预测性能有较大的影响,代表特征重要度较高,则提取该扰动均方误差对应的特征节点,标记为高重要度特征节点;

整合预处理后多维环境参数以及微藻生长参数中所保留的全部高重要度特征节点对应的数据,得到降维筛选后的特征变量数据集;

引入偏最小二乘回归算法,通过偏最小二乘回归算法对所述特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练,得到训练完成的微藻生长预测模型。

[0023] 需要说明的是,由于特征变量随机森林模型的特征节点分布图以及每一特征节点的节点值体现了机器学习训练每个特征数据的潜在训练层次与权重,因此对于特征变量随机森林模型中集成存在的显著影响微藻生长特征的筛选,本方法通过对每一个特征施加扰动特征值来降维评估其重要性,首先基于每一特征节点的节点值对特征变量随机森林模型处于特征节点分布图条件下的初始误差进行计算,从而获取每一特征节点不施加扰动状态下对于模型预测性能的一个初始均方误差,该初始均方误差即为一个判定基准;然后对每一特征节点进行扰动,即打乱该特征的值,并重新计算模型的均方误差,得到一个扰动均方误差。而扰动均方误差相较于初始均方误差之间的均方误差增量便可表达每一特征节点对于微藻生长的特征重要度。其中,若均方误差幅度显示为负值,说明该特征节点对特征变量随机森林模型的预测性能影响较小,即特征重要度较低;若均方误差幅度显示为正值,说明该特征节点对特征变量随机森林模型的预测性能有较大的影响,代表特征重要度较高。最终通过引入偏最小二乘回归算法对特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练来生成微藻生长预测模型。通过本方法能够基于随机森林的特征重要度筛选出对微藻生长影响显著的特征变量,以减少数据冗余与过拟合风险,提高预测模型的训练效率,有效优化模型对于微藻生长的预测性能。

[0024] 更具体地,所述引入偏最小二乘回归算法,通过偏最小二乘回归算法对所述特征变量数据集进行输入特征-输出特征的潜在主成分变量回归训练,得到训练完成的微藻生长预测模型,具体包括以下步骤:

以环境参数为输入特征、微藻生长趋势与代谢产量为输出特征,基于所述降维筛选后的特征变量数据集计算构建输入特征-输出特征协方差矩阵;

引入偏最小二乘回归算法,预设最大协方差距离阈值,通过偏最小二乘回归算法计算输入特征-输出特征协方差矩阵中每个输入特征与每一输出特征之间的协方差距离,得到输入特征-输出特征协方差矩阵内每一矩阵节点的协方差距离;

对于输入特征-输出特征协方差矩阵内的每一个矩阵节点,若协方差距离小于最大协方差距离阈值,则忽略该协方差距离对应的矩阵节点;若协方差距离大于最大协方差

距离阈值,则标记出该协方差距离对应的矩阵节点,定义为最大相关性矩阵节点;

提取最大相关性矩阵节点上关联的输入特征以及输出特征,定义为一组潜在主成分变量,并预设潜在主成分变量的提取数量临界值;

重复上述协方差距离计算判定与输入特征-输出特征协方差矩阵中潜在主成分变量提取的步骤,每次提取一组潜在主成分变量,则更新迭代输入特征与输出特征之间的关系,得到潜在主成分变量的当前提取数量;

若当前提取数量未达到所述提取数量临界值,则继续输入特征-输出特征协方差矩阵的协方差距离计算判定与潜在主成分变量提取;若当前提取数量已达到所述提取数量临界值,则停止潜在主成分变量提取,得到提取出的潜在主成分变量集;

利用所述提取出的潜在主成分变量集在偏最小二乘回归算法中构建输入特征与输出特征之间的回归模型,通过所述回归模型对训练集进行回归训练运算,得到训练完成的微藻生长预测模型。

[0025] 需要说明的是,微藻生长的趋势以及代谢产量指标对于后续微藻的精准培养至关重要,因此微藻生长预测而言,通常以现有的环境参数为输入特征、微藻生长趋势与代谢产量为输出特征的形式来实现,但现有的预测模型难以实现对于现有环境参数与所需得知的微藻生长趋势、代谢产量之间的相关性筛选训练,使得在分析某一个输出特征时欲知道其与哪些输入特征之间可能存在必要关联难以做出决策结论,例如微藻生长的趋势以及代谢产量可能受到输入特征中的温度所影响,可从温度方面优化,上述问题从而使得后续微藻生长培养无法做出对应精准的改善和优化。因此本方法通过引入偏最小二乘回归算法训练降维筛选后的特征变量数据集,偏最小二乘回归算法的核心思想是寻找一组新的主成分变量,而这些主成分变量在自变量空间中具有最大的方差,同时这些主成分变量也尽可能地与因变量之间的相关性最大化,因此首先需将降维筛选后的特征变量数据集计算构建输入特征-输出特征协方差矩阵;接着计算每个输入特征与每一输出特征之间的协方差距离,若协方差距离小于最大协方差距离阈值,说明该矩阵节点上的某个输入特征与输出特征之间的相关性较低甚至不存在密切关联,因此忽略该协方差距离对应的矩阵节点;若协方差距离大于最大协方差距离阈值,说明矩阵节点上的某个输入特征与输出特征之间的相关性达到最大值,故而标记该矩阵节点为最大相关性矩阵节点。一方面能够确保数据训练过程中环境参数与微藻生长的趋势、代谢产量之间的特征预测关联度,便于后续微藻生长培养的精准优化;另一方面能够降低预测模型的复杂性,避免维度过高引起的过拟合问题。

[0026] 需要说明的是,其中每次提取一组潜在主成分变量则更新迭代输入特征与输出特征之间的关系直至达到提取数量临界值为止,这能够确保模型能够充分捕捉数据中的重要信息,同时减少冗余主成分的引入,优化模型的预测性能和泛化能力。最终将提取的最大相关性矩阵节点上关联的输入特征以及输出特征作为一组潜在主成分变量来建立自变量与因变量之间的回归模型,通过回归模型对训练集进行回归训练运算便可生成微藻生长预测模型。通过本方法能够在机器学习算法训练现有环境参数过程中对输入特征与输出特征之间的相关性进行最大化筛选分析,从而降维回归训练出高效精准的微藻生长预测模型,实现预测结果特征与现有数据特征保持高度关联性,为后续微藻生长的培养优化提供溯源数据,提高培养优化的精准性。其中,偏最小二乘回归算法是机器学习算法中最具代表性的一种常用于高维数据或多重共线性数据的统计方法,采用偏最小二乘回归算法能够同时考虑

自变量和因变量的最大信息相关性,因此具有较好的预测训练能力。

[0027] 更具体地,所述S106步骤,如图2所示,具体包括以下步骤:

S202:获取微藻实际培养过程的实时微藻生长环境参数,将所述实时微藻生长环境参数导入训练完成的微藻生长预测模型进行未来时间段的生长预测,以输出未来特定时间段内的实际微藻生长预测趋势与实际代谢预测产量;

S204:获取微藻生长预测模型处于预设培养时序上预测培养条件动态变化时输出的实际微藻生长预测趋势与实际代谢预测产量,得到培养条件动态变化时的多个实际预测结果;

S206:引入贝塞尔曲线法,通过贝塞尔曲线法将多个所述实际预测结果进行曲线拟合,得到实际预测结果的贝塞尔曲线,定义为第一贝塞尔曲线;同步获取培养条件动态变化下的期望预测结果,构建期望预测结果的贝塞尔曲线,定义为第二贝塞尔曲线;

S208:若第一贝塞尔曲线的斜率与第二贝塞尔曲线的斜率之间的斜率偏差值大于预设斜率偏差值,则基于斜率偏差值跟踪训练完成的微藻生长预测模型位于培养条件动态变化过程中的历史梯度平方并进行指数加权,得到一个滑动平均值;

S210:跟踪过程中,获取微藻生长预测模型的当前学习率,通过滑动平均值对所述当前学习率进行调整更新,以使得训练完成的微藻生长预测模型适应动态变化的培养条件。

[0028] 需要说明的是,由于微藻生长培养是一个相对动态变化的过程,如若微藻生长预测模型未能够及时做出更新反应,则可能导致当前预测模型的学习率无法跟随培养条件动态变化,使得预测模型无法适应微藻生长动态变化的培养条件,造成预测结果相较于培养条件动态变化而言存在滞后现象,预测结果存在偏差,因此需要对微藻生长预测模型执行定时更新。针对此,本方法通过微藻生长预测模型获取多个培养条件动态变化的实际预测结果,以及获取培养条件动态变化下的期望预测结果,然后以贝塞尔曲线法分别构建这两者各自的贝塞尔曲线,即第一贝塞尔曲线与第二贝塞尔曲线,贝塞尔曲线法可通过良好的连续性和光滑性曲线斜率精准反映两组数据之间的拟合变量与误差,从而使实际预测结果与期望预测结果之间的滞后幅度偏差定位更加高效准确,进一步优化预测模型更新的速率,节省繁琐与不必要的运算步骤,减少预测模型的更新误差率。其中,若第一贝塞尔曲线的斜率与第二贝塞尔曲线的斜率之间的斜率偏差值大于预设斜率偏差值,说明当前微藻生长预测模型对于培养条件动态变化的预测性能存在较大的滞后偏差现象,因此需基于该斜率偏差值跟踪计算微藻生长预测模型位于培养条件动态变化过程中的历史梯度平方的滑动平均值,通过滑动平均值对当前微藻生长预测模型的学习率进行调整更新,实现预测模型不同在线增量学习的效果。通过本方法能够基于培养条件动态变化下当前微藻生长预测模型的预测结果滞后偏差来跟踪更新其学习率,使得训练完成的微藻生长预测模型适应动态变化的培养条件,以确保微藻生长预测模型适应动态变化的培养条件。

[0029] 更具体地,所述S108步骤,具体包括以下步骤:

获取微藻生长培养计划,通过所述微藻生长培养计划获取微藻生长培养的目标函数;其中,所述目标函数包括最大生物量产出、最佳代谢产物合成率、最低资源消耗;

基于未来特定时间段内的微藻生长预测趋势、代谢预测产量以及所述目标函数设定满足于微藻生长培养计划的优化目标;

通过微藻生长培养计划提取不同生长培养参数的预设调控区间,根据所述不同生长培养参数的预设调控区间构建既定参数调控空间;

引入遗传算法,通过遗传算法构建既定参数调控空间的多个初始遗传种群,基于优化目标对各个初始遗传种群中的每一生长培养参数个体进行适应度评估,得到若干个适应度值;

只提取最大适应度值的生长培养参数个体,标记为父代个体,并对所述父代个体进行遗传交叉以及变异操作,生成新生子代个体,将每个初始遗传种群的新生子代个体搜索替代对应的父代个体,直至种群适应度达到预设适应度阈值为止,最终输出微藻生长的最优培养条件参数集;

通过闭环控制策略,将所述最优培养条件参数集下发至微藻生长的实际培养过程,以实时调节微藻生长的环境条件,并监控微藻生长表现将最新状态数据反馈入预测模型与优化模块,形成动态优化闭环。

[0030] 需要说明的是,在获取到微藻生长趋势以及代谢产量的预测结果后,便可根据该预测结果对培养条件进一步做出优化决策,但传统预测模型难以实现根据预测结果自动化规划搜索微藻生长的最优培养条件,仍需要借助人工干预的方式手动最优化运算,步骤繁琐且费时费力,大大降低了微藻生长培养优化的速率,且可能存在较大的人工干预误差,减少了微藻生长培养优化的精准率,使得最终培养出的微藻样本难以满足预期培养要求。因此需要为预测模型赋予自动根据预测结果搜索最优培养条件的决策机制。对此,本方法基于预测结果与目标函数设定满足于微藻生长培养计划的优化目标,并通过微藻生长培养计划构建不同生长培养参数的既定参数调控空间,然后利用遗传算法,基于优化目标的适应度计算在既定参数调控空间的初始遗传种群内进行子代个体对父代个体的遗传交叉变异操作分析,以此便可搜索出微藻生长的最优培养条件参数集,最后将最优培养条件参数集应用至微藻生长的实际培养过程来实时调节微藻生长的环境条件,并监控微藻生长表现将最新状态数据反馈入预测模型与优化模块。通过本方法能够基于预测结果为微藻生长搜索最优的培养条件参数,从而实现对微藻生长趋势与代谢产率的实时调优,可有效提升微藻培养效率,降低运营成本,提高目标微藻产物的产量,经济效益大幅提升。

[0031] 更具体地,所述并实时监控微藻生长表现将最新状态数据反馈入预测模型与优化模块,形成动态优化闭环,具体包括以下步骤:

通过在线监测设备实施连续监控微藻生长状态表现,得到当前生长状态变量,并建立微藻生长培养-预测-优化的闭环状态控制模型;

引入极点配置法,通过极点配置法对所述当前生长状态变量进行闭环状态控制模型的闭环反馈计算,得到当前微藻生长状态的闭环反馈增益矩阵,将所述闭环反馈增益矩阵导入闭环状态控制模型中补偿控制,生成当前微藻生长状态的闭环反馈控制器;

将所述当前微藻生长状态的闭环反馈控制器部署于实际微藻生长培养-预测-优化流程中,得到当前微藻生长的最新相关状态数据,并最终将最新相关状态数据反馈到微藻生长预测模型的预测模型与优化模块,以形成动态优化闭环。

[0032] 需要说明的是,由于微藻的生长是一个动态变化过程,因此其生长状态是时刻发生不同变化的,且从微藻生长的培养、预测直至到生长培养优化是一个相对完整闭环的系统化流程,因此本方法通过构建该流程的闭环状态控制模型,然后利用极点配置法对当前

生长状态变量进行闭环控制反馈,以此便可获取当前生长状态所需反馈的一些性能参数增益,即闭环反馈增益矩阵;接着将该闭环反馈增益矩阵注入闭环状态控制模型中补偿控制计算,从而构建出一个当前微藻生长状态的闭环反馈控制器,该闭环反馈控制器能够通过当前生长状态的反馈增益以保证闭环系统的稳定性,使得预测模型对于微藻生长培养的动态优化更加精准稳定。最终将该闭环反馈控制器部署于实际微藻生长培养-预测-优化流程中便能够得到当前微藻生长的最新相关状态数据,将最新相关状态数据反馈到微藻生长预测模型的预测模型与优化模块。通过本方法能够使微藻生长培养的预测优化形成动态优化闭环,以根据当前微藻的生长状态实时改善预测模型以及优化培养策略,从而实现培养条件的自动或半自动优化,相较于传统预测优化方法而言更加有效提高微藻产量与目标代谢产物的合成效率。

[0033] 本发明第二方面提供了一种基于机器学习的微藻生长预测与优化系统,如图3所示,所述微藻生长预测与优化系统包括存储器31与处理器32,所述存储器31中储存一种基于机器学习的微藻生长预测与优化方法程序,所述微藻生长预测与优化方法程序被所述处理器32执行时,实现任一项所述的微藻生长预测与优化方法步骤。

[0034] 以上,仅为本发明的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,可轻易想到变化或替换,都应涵盖在本发明的保护范围之内。因此,本发明的保护范围应以权利要求的保护范围为准。

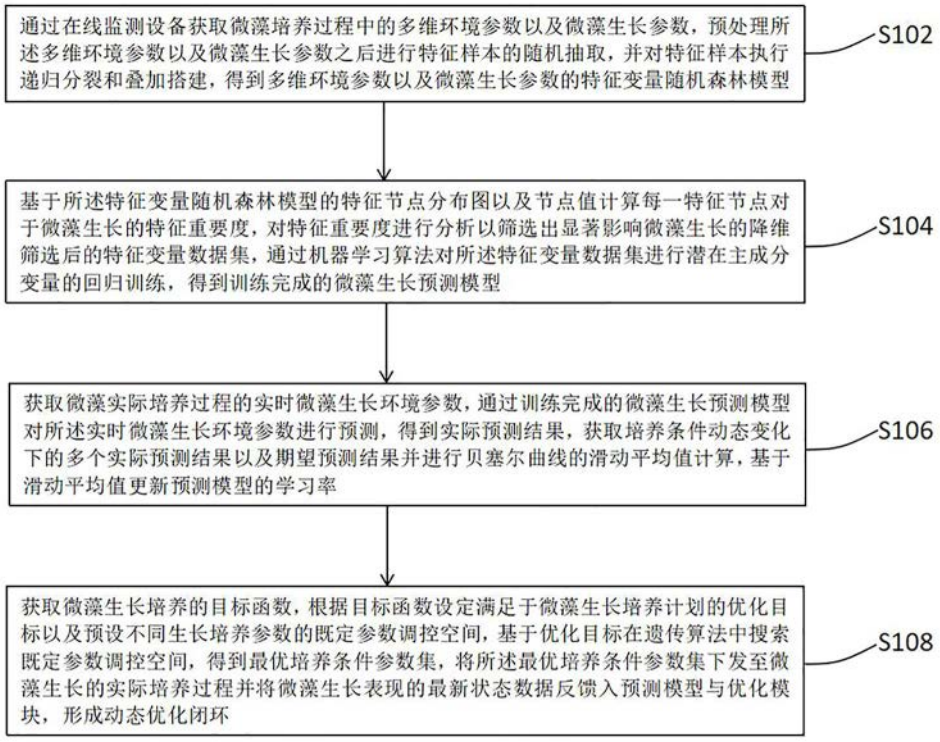
通过在线监测设备获取微藻培养过程中的多维环境参数以及微藻生长参数，预处理所述多维环境参数以及微藻生长参数之后进行特征样本的随机抽取，并对特征样本执行递归分裂和叠加搭建，得到多维环境参数以及微藻生长参数的特征变量随机森林模型
S102
基于所述特征变量随机森林模型的特征节点分布图以及节点值计算每一特征节点对于微藻生长的特征重要度，对特征重要度进行分析以筛选出显著影响微藻生长的降维筛选后的特征变量数据集，通过机器学习算法对所述特征变量数据集进行潜在主成分变量的回归训练，得到训练完成的微藻生长预测模型
S104
获取微藻实际培养过程的实时微藻生长环境参数，通过训练完成的微藻生长预测模型对所述实时微藻生长环境参数进行预测，得到实际预测结果，获取培养条件动态变化下的多个实际预测结果以及期望预测结果并进行贝塞尔曲线的滑动平均值计算，基于滑动平均值更新预测模型的学习率
S106
获取微藻生长培养的目标函数，根据目标函数设定满足于微藻生长培养计划的优化目标以及预设不同生长培养参数的既定参数调控空间，基于优化目标在遗传算法中搜索既定参数调控空间，得到最优培养条件参数集，将所述最优培养条件参数集下发至微藻生长的实际培养过程并将微藻生长表现的最新状态数据反馈入预测模型与优化模块，形成动态优化闭环
S108

图 1

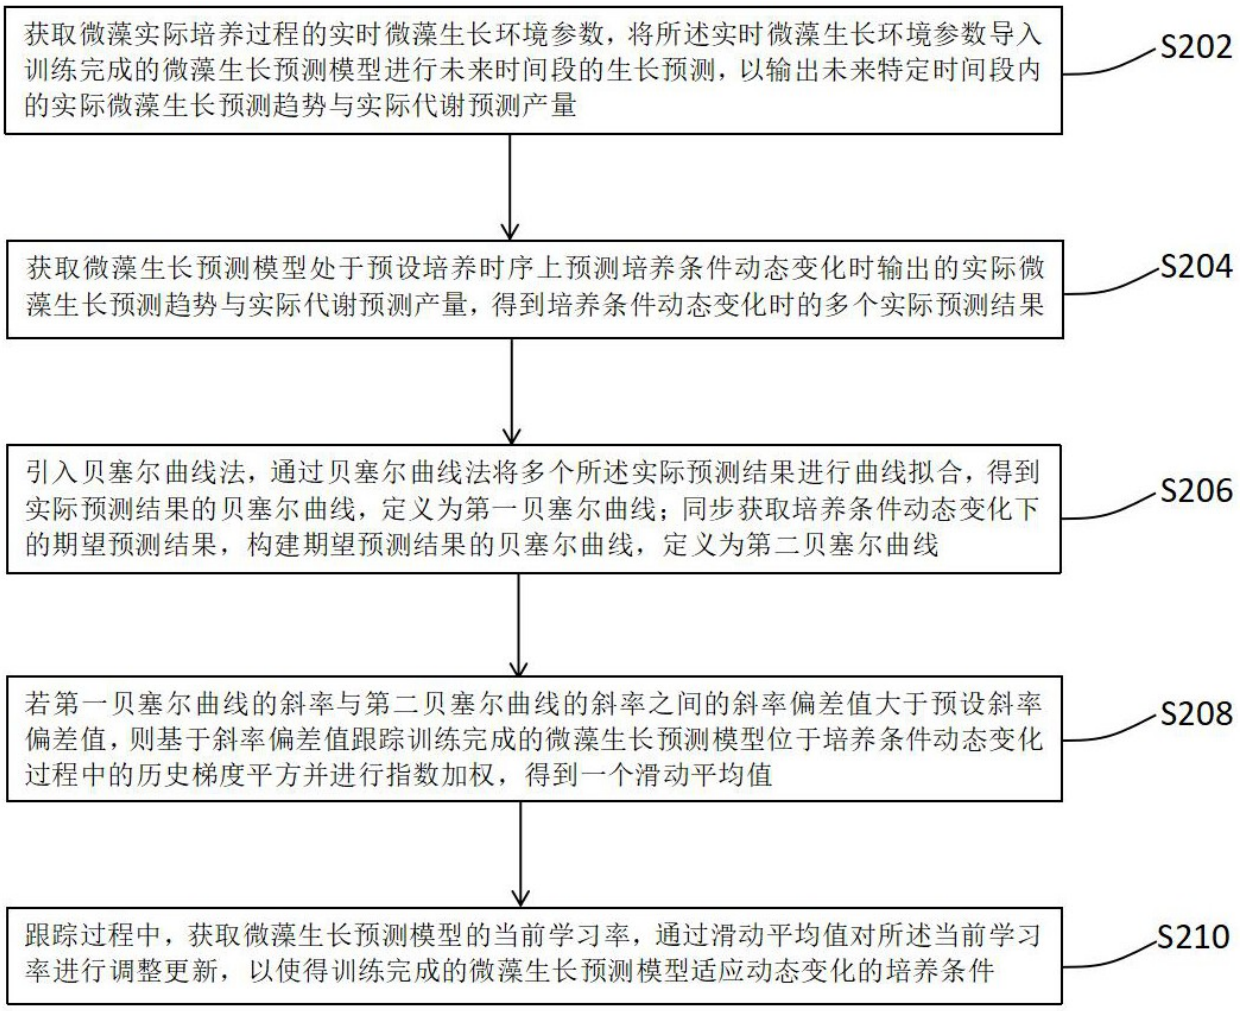
获取微藻实际培养过程的实时微藻生长环境参数，将所述实时微藻生长环境参数导入训练完成的微藻生长预测模型进行未来时间段的生长预测，以输出未来特定时间段内的实际微藻生长预测趋势与实际代谢预测产量
S202
获取微藻生长预测模型处于预设培养时序上预测培养条件动态变化时输出的实际微藻生长预测趋势与实际代谢预测产量，得到培养条件动态变化时的多个实际预测结果
S204
引入贝塞尔曲线法，通过贝塞尔曲线法将多个所述实际预测结果进行曲线拟合，得到实际预测结果的贝塞尔曲线，定义为第一贝塞尔曲线；同步获取培养条件动态变化下的期望预测结果，构建期望预测结果的贝塞尔曲线，定义为第二贝塞尔曲线
S206
若第一贝塞尔曲线的斜率与第二贝塞尔曲线的斜率之间的斜率偏差值大于预设斜率偏差值，则基于斜率偏差值跟踪训练完成的微藻生长预测模型位于培养条件动态变化过程中的历史梯度平方并进行指数加权，得到一个滑动平均值
S208
跟踪过程中，获取微藻生长预测模型的当前学习率，通过滑动平均值对所述当前学习率进行调整更新，以使得训练完成的微藻生长预测模型适应动态变化的培养条件
S210

图 2

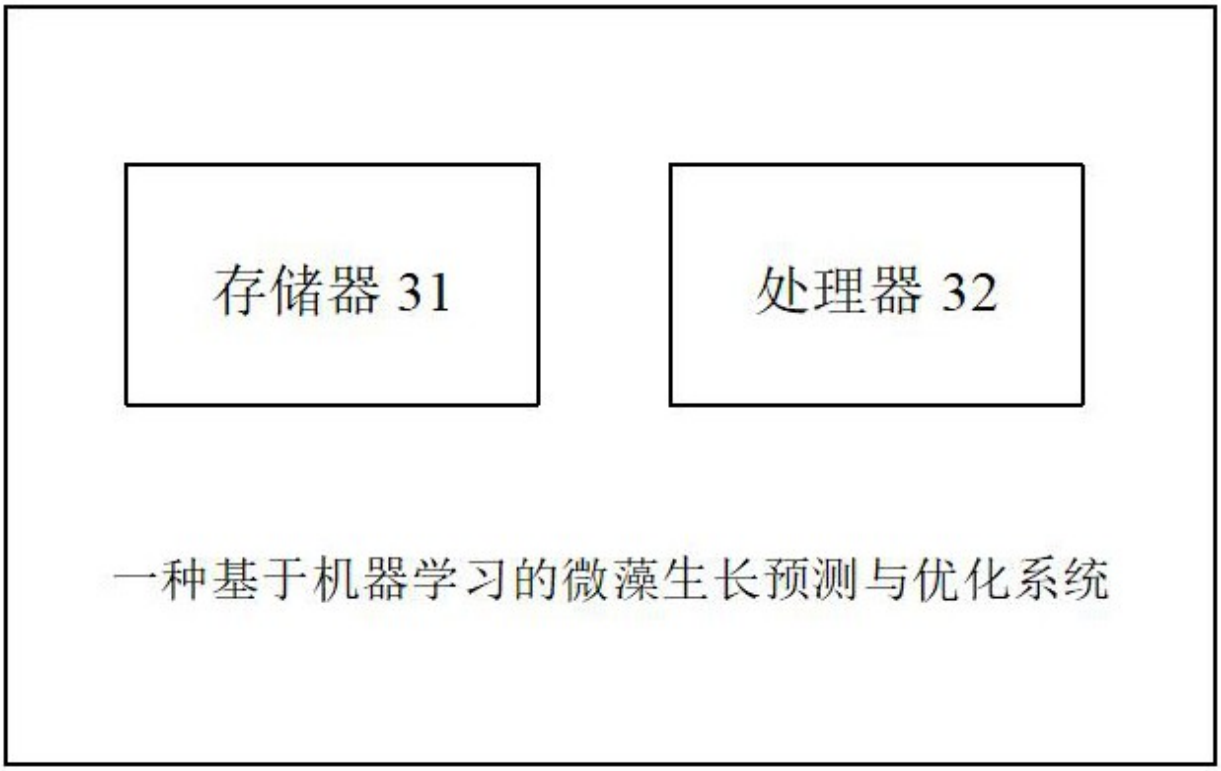

图 3